

Titre du mini-projet

Conception et implémentation d'un moteur de recherche sémantique basé sur une base de données vectorielle

Objectifs pédagogiques

À l'issue de ce mini-projet, l'étudiant sera capable de :

- Comprendre le fonctionnement des bases de données vectorielles
- Générer des représentations vectorielles (embeddings)
- Concevoir une architecture complète de recherche sémantique
- Implémenter une recherche par similarité
- Comparer recherche lexicale vs recherche sémantique
- Rédiger un rapport technique structuré

Contexte général du projet

Une organisation (université, centre de recherche ou entreprise) souhaite mettre en place un système de recherche intelligent permettant de retrouver des documents par sens et non par mots-clés exacts.

Le système doit permettre à un utilisateur de :

- saisir une requête en langage naturel
- obtenir les documents les plus proches sémantiquement

Technologies imposées (Open Source)

- **Langage** : Python
- **Base de données vectorielle** :
 - PostgreSQL + pgvector
- **Traitement NLP** :
 - Sentence-Transformers
- **Jeux de données publics** :
 - Kaggle
 - ou Hugging Face

Jeu de données (au choix)

Les étudiants peuvent choisir un dataset public, par exemple :

- Résumés d'articles scientifiques (arXiv)
- Articles de presse
- FAQ techniques
- Documents juridiques courts
- Avis clients (reviews)
- En medecine: Cas cliniques (MIMIC-III – version textuelle), datasets médicaux sur PhysioNet, Descriptions de maladies (Hugging Face)

Le dataset doit contenir au minimum 1 000 documents textuels.

Travail demandé

Phase 1 – Analyse et conception

- Présentation du problème
- Choix du dataset
- Schéma d'architecture du système
- Choix de la méthode de vectorisation
- Modélisation de la base de données

Phase 2 – Implémentation de la base vectorielle

- Prétraitement des données textuelles
- Génération des embeddings
- Stockage des vecteurs dans la base
- Indexation vectorielle

Phase 3 – Recherche sémantique

- Vectorisation de la requête utilisateur
- Calcul de similarité (cosinus ou L2)
- Retour des k documents les plus proches
- Comparaison avec une recherche classique (TF-IDF ou mots-clés)

Phase 4 – Validation et analyse critique

- Tests fonctionnels
- Analyse des performances
- Limites du système
- Propositions d'amélioration

Livrables finaux obligatoires

Dossier à remettre :

1. Code source documenté
2. Script SQL ou configuration FAISS
3. Rapport final (**10–15 pages**) incluant :
 - Introduction
 - État de l’art (bases vectorielles)
 - Méthodologie
 - Implémentation
 - Résultats
 - Discussion critique
 - Conclusion

Bonus (facultatif)

- Support multilingue
- Comparaison de plusieurs modèles d’embeddings